

MLX-FINETUNE-TEST — GÖRSEL PIPELINE

Ham veri setinden, servise alınmış ve doğrulanmış bir modele

veri hazırlama fine-tuning servis

1 • VERİ

KAYNAK**Kaggle: Phishing Email Detection**

18.650 email · Email Text + Email Type

subhjournal/phishingemails

TEMİZLE**prepare_data.py**boş + 1.068 duplicate atıldı, uzunluk 1.000
karakterle sınırlandı

python scripts/prepare_data.py

SPLIT**Stratified train/valid**9.356 kaldı → 8.420 train / 936 valid, oran
korunuyor

train.jsonl · valid.jsonl

2 • FINE-TUNING

BASE MODEL**Qwen3-4B-abliterated**

4-bit MLX, 2.26GB, eğitim boyunca donuk

mlx-community/Josiefied-Qwen3-4B

EĞİT**LoRA fine-tune**1000 iters, batch 4 — parametrelerin sadece
%0,18'i eğitildi

mlx_lm.lora --train

DOĞRULA**Checkpoint kontrolü**en düşük val-loss'lu checkpoint tek bir sınıf
tahmin ediyordu — loss'a değil gerçek çıktıya
göre seçildi

scripts/evaluate.py → 6/6

3 • SERVİS

FUSE**Adapter'ı birleştir → fp16**

LoRA ağırlıkları base model içine katlandı

mlx_lm.fuse --dequantize

ÇEVİR**→ GGUF, sonra quantize**

Q4_K_M: 8GB → 2.4GB

convert_hf_to_gguf.py · llama-quantize

SERVİS ET**llama-server**OpenAI-uyumlu API, key zorunlu, CORS →
localhost

POST /v1/chat/completions

run_pipeline.py --serve son 3 node'u uçtan uca yönetir

tüm aşamalar gerçek çıktıya karşı doğrulandı