

VAKIFBANK SOC — STAJ PRATIK PROJESİ

mlx-finetune-test

Apple Silicon üzerinde (MLX) yerel bir LLM'in LoRA ile fine-tuning'i — sentetik bir smoke test'ten, bir yerel API üzerinden servis edilen çalışan bir phishing-email sınıflandırıcıya kadar uçtan uca.

4B param

Qwen3-4B-abliterated, 4-bit

18.6k email

Kaggle phishing veri seti, ham

1000 iters

LoRA fine-tuning, batch 4

6/6 doğru

held-out phishing/safe test

01**Pipeline'ı doğrula** DUMMY VERİ

Gerçek veriye geçmeden önce, modeli sentetik bir görevle eğittik — her yanıtı sabit bir [SOC-TEST] marker eklemek — başarı bir loss sayısında değil, doğrudan çıktıda görülsün diye seçildi.

25 train / 5 valid satır

iters 200, batch 2

val loss 6.59 → 0.50

cross-lingual + parafraz genelleme başarılı

02**Gerçek veri: phishing email'ler** KAGGLE

Sentetik görev, gerçek bir görevle değiştirildi — email'leri Phishing ya da Safe olarak sınıflandırmak. Ham veri, eğitilebilir hale gelmeden önce gerçek bir temizlik gerektirdi.

1.068 duplicate atıldı (leakage riski)

uzunluk 1.000 karakterle sınırlandı (kuyruk 17M'e kadar uzuyordu)

18.650 email'den 9.356'sı kaldı

stratified %90/10 split → 8.420 train / 936 valid

03 Fine-tune et — ve val loss'a tek başına güvenme KILIT DERS

Val loss erken aşamada en iyi görünüyordu, ama düşük-loss checkpoint'i sadece çoğunluk sınıfını tahmin etmeyi öğrenmişti. Gerçek üretim çıktısı tek güvenilir sinyaldi.

iters 1000, batch 4

temizlik sonrası 8.420 train satırı

Iter 200, en düşük erken val loss'a sahipti (3.03) — ve açık phishing örnekleri dahil her email'e "Safe" diyordu. Görevi değil, sınıf dengesini öğrenmişti. Eğitime iter 1000'e kadar devam edildi, checkpoint'ler seçilmeden önce elle yazılmış 6 email'e karşı doğrulandı.

val loss — iter 1: 4.76 → 200: 3.03 → 400: 3.22 → 700: 2.96 → 1000: 3.15 (non-monotonic)

04 Servise al LLAMA.CPP

Tamamlanan adapter, base model ile birleştirilir (fuse), GGUF'a çevrilir, quantize edilir ve bir OpenAI-uyumlu API arkasında servise alınır — auth ile, açıkta bırakılmadan.

fuse → GGUF → Q4_K_M quantize (8GB → 2.4GB)

llama-server, OpenAI-uyumlu endpoint

API key zorunlu, CORS localhost'a kısıtlı

ÖZETLE

Apple Silicon üzerinde tam bir yerel fine-tuning pipeline'ı kuruldu ve doğrulandı: 4B parametrelilik açık bir model alındı, LoRA ile bir görev öğretildi ve sonuç bir authenticated API arkasında servise alındı — önce mekaniği sentetik bir görevle kanıtlayıp, sonra gerçek bir görevde (phishing email tespiti) tekrarlayarak.

Ana teknik bulgu: **validation-loss eğrisi güvenilir bir durdurma sinyali değildi**

— en düşük loss'a sahip checkpoint, aslında görevi değil çoğunluk sınıfını tahmin etmeyi öğrenmişti. Bunu yakalamak, sadece metriğe değil, gerçek model çıktısına elle bakmayı gerektirdi.